中国移动数据可视化分析

一、数据分析与设计

给出的数据由 5 个小区、10 种数据类型、56 个用户的数据使用量组成,实质上由以下 4 个变量组成:

变量名	类型	取值范围
小区	类型变量	1~5
数据类型	类型变量	微信、小说等 10 种
用户	类型变量	56 个手机号
数据使用量	定距变量	正整数

对这些数据可以进行的数据可视化包括:单个变量的绝对数值分析(例如不同小区的数据使用总量展示)、单个变量的比例分析(例如不同种类的数据所占比例)、多个变量的绝对数值分析(例如不同小区内各种数据类型的使用总量展示)、多个变量的比例分析等等。其中,多个变量的分析还要受到变量顺序的影响,例如不同小区内各种数据类型的使用比例,与不同数据类型内各小区的贡献比例,这两者的展示效果是完全不同的。

考虑到可视化展示的多样性,必须增强交互效果,最终决定使用网页的形式,把上面的信息都集中到一个界面之内。主要的展现形式是绘制多重饼图,跟踪鼠标的位置提供不同级别的数据信息,其中包括使用的数据总量以及占总体的比例。

二、可视化实现

1、使用 Python 进行数据统计工作

在原始的 Excel 数据后面再加一列,填入小区编号(1 到 5),这样就可以把五个工作表的数据合并在一起,另存为 CSV 格式,具体见 Python 文件夹下的 DataVisualizationV2.csv 文件。

使用 Python 文件夹下的 main.py 对数据进行分析,统计出不同小区 Community 内不同数据类型 Type 的使用总量,存为 CT.csv;不同小区 Community 内不同数据类型 Type 下各用户 User 的使用总量,存为 CTU.csv;不同数据类型 Type 下的各小区 Community 的使用总量,存为 TC.csv;不同数据类型 Type 下的各小区 Community 的各用户 User 使用总量,存为 TCU.csv。

之所以没有统计各用户 User 在不同社区 Community 中的使用情况,是因为原始数据中每个用户只隶属于一个小区,所以没有必要进行这项分析,上面的 4 种分析顺序已经包含了所有的数据分析情况。

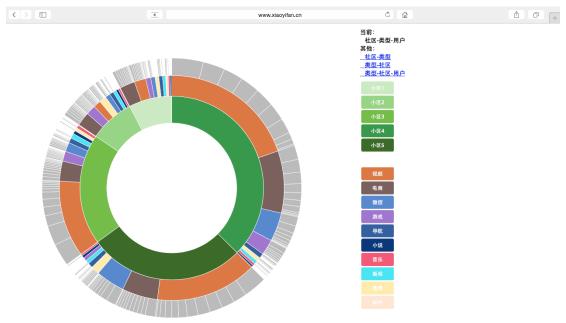
2、搭建 HTML 进行可视化展示

使用 D3 平台编写可视化动画,并进行配色。5 个小区分别用深浅不用的 5 种绿色表示,不同用户均使用灰色,10 种数据类型使用除绿色、灰色之外的 10 种颜色表示。为了保证网页的速度,只有大于 0.005 度的饼图叶会被画出来,而且比例的数据只精确到三个有效数字。

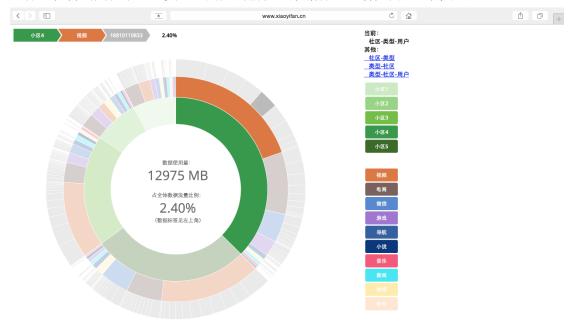
三、成果展示

虽然把网页的源代码已经提交,但是直接打开 index.html 是看不到效果的,因为浏览器不允许直接读取 csv 文件,需要搭建服务器之后才可以打开,本人使用 Apache 服务器,可以访问 http://166.111.131.98/10086/Spark/DataVis/ 查看。

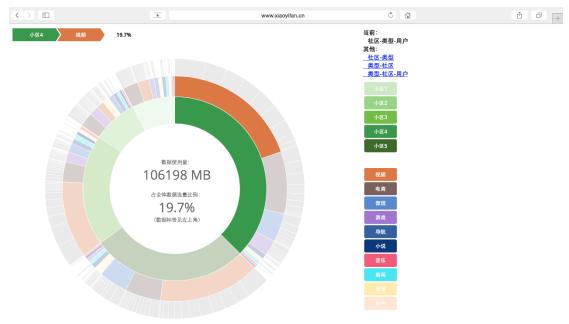
打开网页后的视图如下:



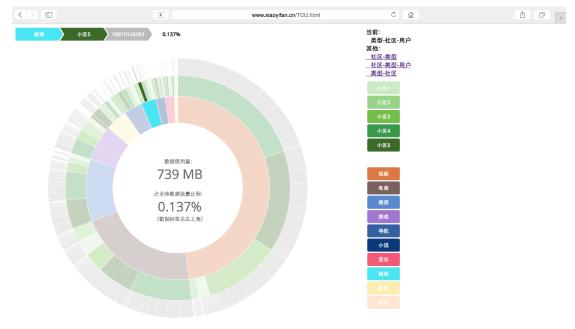
把鼠标移到饼图上,跟随鼠标可以得到数据分析结果,下图得到的信息是:小区 4 中视频类流量里,用户 18810110833 使用了 12975MB,占本次数据分析所有流量的 2.4%。移动鼠标可以得到其他小区、类型、用户的情况。数据标签查看页面左上角即可。



上图中也可以得到前两个变量的情况,把鼠标移到饼图的第二环上即可,结果如下图,信息是小区 4 中使用了 106198MB 视频流量,占总流量的 19.7%。



页面右上角可以点击其他的变量分析顺序,默认是社区→类型→用户的顺序。 点击类型-社区-用户的链接,得到下图的分析结果,图中的信息是:新闻类数据流量中, 小区 5 的 18810126381 用户使用了 739MB,占总体的 0.137%。



也可以选择不包含用户数据的情况,分别点击社区-类型和类型-社区的链接后,效果分别如下:

